

Hierarchical clustering. Angeline Betancart

Let us define an **ultrametric** as a distance function $d_u: X \times X \rightarrow \mathbb{R}_{\geq 0}$ that satisfies

1. **Identity**: $d_u(x, y) = 0 \iff x = y$
2. **Symmetry**: $d_u(x, y) = d_u(y, x)$
3. **ultrametric inequality (strong triangle inequality)**:
$$d_u(x, z) \leq \max\{d_u(x, y), d_u(y, z)\}$$

Theorem: The cophenetic distance d_{coph} from a dendrogram is an ultrametric.

PROOF.

Sea D un dendrograma cuyos nodos internos tienen una altura no negativa, tomemos dos puntos x_i, x_j y definimos la distancia copenética como

$d_{\text{coph}}(x_i, x_j)$ = la altura del nodo en el que x_i y x_j se unen

- identity property

Sea $h_{x_0 x_1}$ la altura del nodo en el que se unen x_0 y x_1 , como la altura de todos los nodos por definición es no negativa entonces $d_{\text{coph}}(x_0, x_1) = h_{x_0 x_1} \geq 0$. Si $x_0 = x_1$ como son el mismo punto la altura del nodo en el que se unen es 0, así $d_{\text{coph}}(x_0, x_0) = h_{x_0 x_0} = 0$.

- Symmetry property

La altura del nodo en el que se unen x_0 y x_1 es la misma del nodo al que se unen x_1 y x_0 por definición, es decir, $d_{\text{coph}}(x_1, x_0) = d_{\text{coph}}(x_0, x_1)$

- ultrametric inequality

Tomemos tres puntos x_0, x_1 y x_2 y definimos sus distancias copenéticas

$$h_{x_0 x_1} = d_{\text{coph}}(x_0, x_1), \quad h_{x_1 x_2} = d_{\text{coph}}(x_1, x_2) \quad \text{y} \quad h_{x_0 x_2} = d_{\text{coph}}(x_0, x_2)$$

Supongamos $h_{x_0 x_1} \leq h_{x_1 x_2}$

(Cuando x_0 y x_1 se unen a la altura $h_{x_0 x_1}$ forman un cluster D , este cluster existe para todas las alturas mayores o iguales a $h_{x_0 x_1}$. Ahora, como $h_{x_0 x_1} \leq h_{x_1 x_2}$ entonces la unión de x_0 y x_2 no puede dejar fuera a x_1 pues a esta altura x_0 ya está unido con x_1 , así el nodo donde x_0 y x_2 se unen contiene todo el cluster D).

De esta forma $h_{x_1 x_2} \leq h_{x_0 x_2}$ ya que a la altura $h_{x_1 x_2}$ x_1 ya se ha unido con x_0 , como definimos $h_{x_0 x_2} \geq h_{x_1 x_2}$ entonces

$$h_{x_0 x_2} = \max\{h_{x_0 x_1}, h_{x_1 x_2}\}$$
$$h_{x_1 x_2} \leq h_{x_0 x_2} = \max\{h_{x_0 x_1}, h_{x_1 x_2}\}$$

wego $h x_1 x_2 \leq \max \{ h x_0 x_1, h x_0 x_2 \}$

Es decir $d_{\text{coph}}(x_1, x_2) \leq \max \{ d_{\text{coph}}(x_0, x_1), d_{\text{coph}}(x_0, x_2) \}$ $q \in D$

$\therefore$ la distancia cofenética es una ultramétrica.