

Procesos Gaussianos

Angeline Betancourt

¿Qué es un Proceso Gaussiano?

- Un proceso gaussiano (GP) es una generalización de la distribución normal multivariada a un espacio de funciones.
- En términos sencillos: si escoges cualquier número finito de puntos del dominio, los valores del proceso en esos puntos tienen una distribución normal multivariada. Permite que, dado un conjunto de datos de entrenamiento, hagamos predicciones sobre nuevos puntos y podamos cuantificar la incertidumbre de esas predicciones.

- Los procesos gaussianos fueron estudiados en estadística y en geología, meteorología, etc., como modelos de campos aleatorios o funciones desconocidas.
- En Machine Learning, se volvieron populares como una aproximación bayesiana no paramétrica para regresión y clasificación.
- Permiten tratar directamente la incertidumbre, a diferencia de modelos determinísticos clásicos.

Aplicaciones principales

- **Regresión:** predecir valores continuos, estimando también un intervalo de confianza.
- **Clasificación probabilística:** en donde queremos estimar probabilidades de clase, no solo una etiqueta dura.
- **Optimización de funciones:** en diseño de experimentos, optimización bayesiana, los GPs sirven como modelo de sustitución de la función objetivo.
- **Modelado espacial o de series de tiempo:** cuando los datos tienen una estructura de correlación en el espacio o en el tiempo, los GPs permiten modelarla mediante funciones de covarianza.

Motivaciones para su uso

- Permite obtener predicciones puntuales y estimar la incertidumbre de esas predicciones (intervalos de confianza) gracias al enfoque bayesiano.
- No fija una forma paramétrica rígida de función (como una recta, un polinomio de grado fijo, etc.), sino que trabaja en un espacio grande de funciones — por eso se dice “no paramétrico”.
- La selección de la función de correlación (kernel) permite adaptar el modelo al tipo de datos (suavidad, periodicidad, estructura espacial, etc.).
- Buena interpretabilidad desde la perspectiva probabilística.

Definición formal

Sea un conjunto de entradas $X = \{x_1, x_2, \dots, x_n\}$ y valores correspondientes $y = \{y_1, y_2, \dots, y_n\}$. Un proceso gaussiano se define mediante una media $\mu(x)$ y una función de covarianza $k(x, x')$.

$$f(x) \sim \mathcal{GP}(\mu(x), k(x, x'))$$

Esto significa que para cualquier conjunto finito de puntos $x_1, \dots, x_n$,

$$\begin{pmatrix} f(x_1) \\ \vdots \\ f(x_n) \end{pmatrix} \sim \mathcal{N}(m, K)$$

donde $m_i = \mu(x_i)$ y $K_{ij} = k(x_i, x_j)$

Predicción en GP para regresión

Asumiendo ruido en observaciones:

$$y = f(x) + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma_n^2)$$

Dado datos de entrenamiento (X, y) y un nuevo punto x_* , la predicción de $f(x_*)$ tiene distribución

$$f(x_*) \mid X, y, x_* \sim \mathcal{N}(\mu_*, \sigma_*^2)$$

con

$$\mu_* = k(x_*, X)[K + \sigma_n^2 I]^{-1}y, \quad \sigma_*^2 = k(x_*, x_*) - k(x_*, X)[K + \sigma_n^2 I]^{-1}k(X, x_*).$$

Aquí $k(x_*, X)$ es el vector de covarianzas entre x_* y cada punto de X , K es la matriz de covarianzas entre los puntos de X . Esta fórmula nos muestra que la predicción depende de la correlación entre el nuevo punto y los existentes.

La función de covarianza (kernel)

- La función $k(x, x')$ (“kernel”) define cuán similares son dos entradas x y x' . Si están muy cerca (o según lo que el kernel defina), su valor de función estará muy correlacionado.
- Ejemplos comunes:

$$k_{\text{RBF}}(x, x') = \exp\left(-\frac{1}{2\ell^2} \|x - x'\|^2\right), \quad k_{\text{Matern}}(x, x') = \dots$$

- Elegir/unir kernels permite incorporar suposiciones sobre la función (suavidad, periodicidad, cambios, etc.)

Código de ejemplo

```
import numpy as np
from sklearn import datasets
from sklearn.gaussian_process import GaussianProcessRegressor
from sklearn.gaussian_process.kernels import RBF, ConstantKernel as C

# Cargar datos
X, y = datasets.load_diabetes(return_X_y=True)
X = X[:, np.newaxis, 2] # tomar una sola característica para simplificar

# Definir kernel: constante × RBF
kernel = C(1.0, (1e-3, 1e3)) *
RBF(length_scale=1.0, length_scale_bounds=(1e-2, 1e2))
```

Código de ejemplo

```
# Crear y entrenar el modelo GP
gpr = GaussianProcessRegressor(kernel=kernel, alpha=1e-2)
gpr.fit(X, y)

# Hacer predicción
X_test = np.linspace(X.min(), X.max(), 100)[: , np.newaxis]
y_pred, y_std = gpr.predict(X_test, return_std=True)
```

Ventajas

- Predicción con estimación de incertidumbre (no sólo un valor puntual).
- Enfoque flexible (no paramétrico) que permite adaptar la complejidad al dato.
- Buena interpretabilidad y fundamento estadístico bayesiano.
- Buena para conjuntos de datos de tamaño moderado, y cuando la incertidumbre es relevante.

Desventajas

- Escalabilidad: el cálculo involucra invertir la matriz de covarianza (o efectuar su factorización), lo cual cuesta $O(n^3)$ en número de datos n .
- Puede perder eficacia cuando el número de características (dimensionalidad) es muy alto o cuando los datos no siguen las suposiciones implícitas del kernel.
- Elección del kernel y sus hiperparámetros puede ser crítica, y requiere experiencia o validación.
- Para grandes volúmenes de datos puede requerir aproximaciones o métodos especiales.

Conclusiones

- Los procesos gaussianos ofrecen un marco poderoso para modelar funciones desconocidas de forma probabilística.
- Permiten predecir y cuantificar incertidumbre — algo valioso en muchas aplicaciones de Machine Learning.
- Requieren hacer elecciones cuidadosas (kernel, hiperparámetros) y considerar las limitaciones de escalabilidad.