

Neutrinos y crecimiento cosmológico utilizando PINN's

Neutrinos and Cosmological Growth Using PINN's

Angeline Betancourt  [Universidad El Bosque | ajbetancourt@unbosque.edu.co]



Universidad El Bosque.

Resumen. En los últimos años, las técnicas de aprendizaje profundo han sido aplicadas cada vez más a la resolución de ecuaciones diferenciales. Entre estos métodos, las *Physics-Informed Neural Networks* (PINN's) se han consolidado como un marco potente que incorpora las leyes físicas que gobiernan el sistema directamente en el proceso de entrenamiento mediante la función de pérdida. En este trabajo investigamos el uso de PINN's para aproximar la solución de la ecuación cosmológica que describe el crecimiento lineal de perturbaciones de materia en presencia de neutrinos masivos. Al incorporar la dinámica de la ecuación de crecimiento dentro de la arquitectura neuronal, el método aprende soluciones continuas y físicamente consistentes sin depender de esquemas de discretización. Presentamos la formulación de la ecuación, el diseño de la función de pérdida que impone las restricciones físicas y la estrategia de entrenamiento empleada para garantizar estabilidad numérica. El desempeño de la PINN se evalúa comparando sus predicciones con soluciones numéricas obtenidas mediante integración directa para diferentes combinaciones del parámetro de estado de la energía oscura w y la fracción de neutrinos f_ν . Los resultados muestran que la PINN reproduce con alta precisión la evolución esperada del crecimiento y captura el efecto de los neutrinos masivos, lo que evidencia su potencial como una alternativa flexible y eficiente a los métodos numéricos tradicionales en cosmología.

Abstract. In recent years, the application of deep learning techniques to the solution of differential equations has gained considerable attention. Among these approaches, Physics-Informed Neural Networks (PINN's) have emerged as a powerful framework that incorporates the governing physical laws directly into the training process through the loss function. In this study, we investigate the use of PINN's to approximate the solutions of the cosmological differential equation that governs the linear growth of matter perturbations in scenarios with massive neutrinos. By embedding the dynamics dictated by the growth equation into the network architecture, the method enables the learning of continuous, physically consistent solutions without relying on traditional discretization schemes. We present the formulation of the governing equation, the construction of a loss function that enforces the physical constraints, and the training strategy adopted to ensure numerical stability. The performance of the PINN is evaluated by comparing its predictions with numerical solutions obtained through direct integration for different combinations of the dark energy equation-of-state parameter w and the neutrino fraction f_ν . The results show that the PINN accurately reproduces the expected behavior of the growth evolution and captures the impact of massive neutrinos, demonstrating its potential as a flexible and efficient alternative to conventional numerical solvers in cosmological modeling.

Palavras-chave: Neutrinos, Neutrino Oscillations, PINN's.

Keywords: Neutrinos, Oscilaciones de Neutrinos, PINN's.

1 Introducción

El estudio de los neutrinos constituye uno de los pilares más relevantes en la física de partículas moderna, debido a su papel esencial en la comprensión de los procesos fundamentales del universo. Estas partículas, que son eléctricamente neutras y tienen una masa extremadamente pequeña, interactúan débilmente con la materia, lo que las convierte en sondas ideales para explorar tanto los procesos astrofísicos de alta energía como la evolución cosmológica a gran escala. La evidencia experimental de que los neutrinos poseen masa, manifestada a través de los fenómenos de oscilación, ha tenido profundas implicaciones en la física contemporánea, pues requiere una extensión del Modelo Estándar e introduce nuevos parámetros asociados a las jerarquías de masa y a las mezclas de sabor [Group, 2024].

En el ámbito cosmológico, las masas de los neutrinos influyen en el crecimiento de las estructuras del universo. En particular, afectan el factor de crecimen-

to lineal al modificar la tasa de formación de galaxias y cúmulos de materia oscura, además de introducir degeneraciones con los parámetros de la energía oscura [Kiakotou *et al.*, 2007]. El trabajo de Kiakotou, Elgarøy y Lahav demuestra que una mayor masa total de neutrinos induce una supresión en el crecimiento de perturbaciones debido a su efecto de *free-streaming*, lo cual puede confundirse con variaciones en la ecuación de estado de la energía oscura. Este tipo de interacciones acopladas entre la materia, los neutrinos y la energía oscura generan sistemas de ecuaciones no lineales.

Los avances recientes en *Deep Learning* han abierto nuevas vías para el estudio de fenómenos físicos complejos, en particular, las *Physics-Informed Neural Networks* (PINN's) constituyen redes neuronales que integran las leyes de la física. A diferencia de otras redes neuronales, las PINN's imponen las ecuaciones diferenciales que gobiernan el sistema directamente en la función de pérdida, garantizando que la solución aprendida

sea coherente con los principios físicos que influyan en el fenómeno estudiado [Raissi *et al.*, 2019].

1.1 Fundamento teórico de los neutrinos

Los neutrinos son leptones neutros con espín 1/2, los cuales tienen tres sabores: electrónico (ν_e), muónico (ν_μ) y tauónico (ν_τ). En el marco del Modelo Estándar, estos se tratan como partículas sin masa, pero la observación de las oscilaciones de sabor, es decir, la transformación periódica entre tipos de neutrinos, demostró que poseen masas finitas y distintas [Fukuda *et al.*, 1998; Ahmad *et al.*, 2002].

En cosmología, los neutrinos desempeñan un papel crucial debido a su abundancia y a su participación en la dinámica de la radiación y la materia. A altas energías, se comportan como partículas relativistas que contribuyen a la radiación cósmica, mientras que a bajas energías, al adquirir masa efectiva, pasan a contribuir a la densidad de materia. Además, su interacción con la energía oscura puede modificar la expansión del universo y el crecimiento de estructuras, lo que ha motivado modelos que consideran acoplamientos directos entre ambos componentes [Brookfield *et al.*, 2007].

Los neutrinos influyen en dos niveles: a nivel de fondo, contribuyendo a la densidad de energía total y modificando la historia de expansión $H(z)$; a nivel de perturbaciones, alterando el crecimiento de las inhomogeneidades gravitacionales debido a su efecto de *free-streaming* (libre propagación). En etapas tempranas (cuando son relativistas) los neutrinos suavizan las perturbaciones a pequeñas escalas; cuando se vuelven no relativistas, comienzan a comportarse como materia, pero su dispersión térmica residual continúa suprimiendo el crecimiento en escalas menores a su longitud de free-streaming [Lesgourgues and Pastor, 2006; Kiakotou *et al.*, 2007].

Estas características hacen que los neutrinos establezcan la conexión entre la física de partículas y la evolución de las estructuras cósmicas, afectando el crecimiento lineal de las perturbaciones de densidad y la interpretación de parámetros cosmológicos ligados a la energía oscura.

1.1.1 Ecuación de Friedmann

El universo a gran escala puede describirse mediante la métrica de Friedmann–Lemaître–Robertson–Walker (FLRW), que asume homogeneidad e isotropía. En un universo plano ($k = 0$), la ecuación de Friedmann es

$$H^2 = \left(\frac{\dot{a}}{a}\right)^2 = \frac{8\pi G}{3}\rho_{\text{tot}}, \quad (1)$$

donde ρ_{tot} incluye materia, radiación, energía oscura y neutrinos. Si la energía oscura se modela como un fluido con ecuación de estado constante $w = p_{\text{de}}/\rho_{\text{de}}$, y considerando Ω_{m0} como la densidad de materia actual, la dependencia de $H(z)$ con el corrimiento al rojo es [Kiakotou *et al.*, 2007]:

$$H(z) = H_0 \sqrt{\Omega_{m0}(1+z)^3 + (1-\Omega_{m0})(1+z)^{3(1+w)}}. \quad (2)$$

Esta ecuación describe cómo la materia y la energía oscura determinan la expansión cósmica. La inclusión de neutrinos afecta $H(z)$ a través de su contribución a Ω_{m0} , y, por extensión, modifica la evolución temporal del crecimiento estructural.

1.1.2 Perturbaciones lineales y la ecuación de crecimiento

El crecimiento de las estructuras se estudia a través de la teoría de perturbaciones lineales. Definimos la sobredensidad como $\delta_i(\mathbf{x}, t) = \delta\rho_i/\bar{\rho}_i$ para cada componente i . En el régimen lineal, las ecuaciones de evolución para las perturbaciones en el espacio de Fourier toman la forma general:

$$\ddot{\delta}_i + 2H\dot{\delta}_i = 4\pi G \sum_j \bar{\rho}_j \delta_j. \quad (3)$$

Para la materia fría (CDM), los neutrinos afectan el término gravitacional al no participar completamente del colapso a escalas menores a la longitud de free-streaming. Este efecto puede modelarse introduciendo un factor de supresión $(1 - f_\nu)$, donde

$$f_\nu = \frac{\Omega_\nu}{\Omega_m}$$

es la fracción de la densidad de materia en forma de neutrinos. Así, la ecuación que gobierna la evolución lineal de la sobredensidad total en presencia de neutrinos se expresa como

$$\ddot{\delta} + 2\frac{\dot{a}}{a}\dot{\delta} = 4\pi G\bar{\rho}_m(1 - f_\nu)\delta. \quad (4)$$

Esta forma efectiva refleja que los neutrinos suavizan el crecimiento de perturbaciones en función de su masa y abundancia. Su deducción completa requiere resolver la jerarquía de Boltzmann para el fluido neutrínico, pero la aproximación $(1 - f_\nu)$ reproduce correctamente el comportamiento a primer orden [Lesgourgues and Pastor, 2006].

Finalmente, la siguiente ecuación describe la evolución del factor de crecimiento lineal $f(a) = \frac{d\ln D}{d\ln a}$ en presencia de neutrinos masivos y energía oscura con ecuación de estado variable $w(a)$:

$$\frac{df}{d\ln a} + f^2 + \left[2 + \frac{1}{2}(1 - 3w(a)\Omega_{\text{DE}}(a))\right]f = \frac{3}{2}\Omega_m(a)[1 - f_\nu], \quad (5)$$

donde $f_\nu = \Omega_\nu/\Omega_m$ representa la fracción de materia correspondiente a neutrinos. Esta ecuación encapsula la influencia de los neutrinos en la dinámica del crecimiento de estructuras: a mayor f_ν , más fuerte es la supresión del crecimiento.

El estudio de estas tres ecuaciones permite comprender cómo la masa de los neutrinos modifica el crecimiento de las perturbaciones y su relación con la energía oscura. En el presente trabajo, se propone resolver la ecuación (4) y (5) mediante el uso de técnicas de aprendizaje profundo basadas en física, con el fin de analizar la evolución de los neutrinos.

2 Metodología

En esta sección se describe a detalle la metodología seguida para resolver las ecuaciones (4) y (5) mediante PINN's, se describe la obtención de los datos, el tipo de arquitectura utilizada y el razonamiento detrás de esta, además la PINN fue probada en una ecuación sencilla que se asemeja a la forma de la ecuación objetivo con el propósito de validar el funcionamiento de la red planteada.

2.1 Simulación de los datos

Con el fin de entrenar y validar el modelo, se generaron datos sintéticos resolviendo numéricamente la ecuación de crecimiento lineal (4) bajo distintos escenarios cosmológicos caracterizados por los parámetros (Ω_{m0}, w, f_ν) . La integración se realizó empleando el método `odeint`, obteniendo la solución continua $\delta(z)$ para un conjunto denso de valores de redshift.

2.2 Implementación con PINN's

Para facilitar el entrenamiento de la PINN, se reparametrizó la variable independiente en términos de

$$\lambda = \ln a = -\ln(1+z),$$

lo cual mejora la estabilidad numérica y permite un cálculo más eficiente de derivadas mediante diferenciación automática. La solución obtenida numéricamente se interpola en función de λ y posteriormente se divide en conjuntos de entrenamiento y prueba, preservando la estructura del dominio físico y garantizando evaluaciones consistentes de generalización.

Con el fin de evaluar la ecuación diferencial y construir la función de pérdida de la PINN, se implementaron funciones destinadas a calcular cantidades cosmológicas dependientes del corrimiento al rojo z . En particular, se definieron expresiones para el parámetro de Hubble $H(z)$ (ecuación 2) y la fracción de densidad de materia $\Omega_m(z)$ bajo el supuesto de un universo plano con energía oscura de ecuación de estado constante w .

La fracción de densidad de materia $\Omega_m(z)$ se calcula mediante:

$$\Omega_m(z) = \frac{\Omega_{m0}(1+z)^3}{H^2(z)/H_0^2}.$$

Asimismo, se introduce el parámetro auxiliar $\alpha(z)$, empleado en la formulación reducida de la ecuación diferencial. Este se aproxima mediante

$$\alpha(z) = \alpha_0 + \alpha_1 [1 - \Omega_m(z)],$$

donde los coeficientes α_0 y α_1 dependen únicamente del valor de w . Las funciones fueron implementadas en versiones tanto `NumPy` como `PyTorch`, permitiendo su uso eficiente durante el entrenamiento de la PINN y en las comparaciones numéricas de referencia.

2.3 Arquitectura de la PINN

El modelo empleado corresponde a una red neuronal totalmente conectada (MLP), diseñada para apro-


ximar simultáneamente las funciones $\ln \delta(\lambda)$, donde

$$f(\lambda) = \frac{d \ln \delta}{d \ln a}.$$

La arquitectura adoptada consta de:

- Una capa de entrada con una única neurona correspondiente a λ .
- Varias capas ocultas densas que emplean la función de activación `Tanh`, seleccionada por su suavidad y derivabilidad, características indispensables para la formación de derivados de segundo orden.
- Una capa de salida con dos neuronas: una para $\ln \delta$ y otra para f .

A continuación se presenta la arquitectura:



Xavier Initialization

Figura 1. Diagrama de la arquitectura utilizada para la PINN

Esta estructura se eligió por su capacidad para representar funciones continuas y suaves, requisito fundamental en el aprendizaje de ecuaciones diferenciales ordinarias asociadas al crecimiento estructural. La arquitectura fue adecuada de forma que solucionara de forma eficaz la ecuación de prueba $y'' = 2y$, en este caso se utiliza la función de activación `tanh()` ya que esta garantiza suavidad y permite obtener las derivadas mediante derivación automática (`autograd`).

2.3.1 Formulación física de la función de pérdida

La clave de las PINN's radica en la incorporación directa del conocimiento físico mediante la imposición de las ecuaciones diferenciales gobernantes. Para ello, se emplea la diferenciación automática de `PyTorch` con el fin de obtener:

$$\frac{d(\ln \delta)}{d\lambda}, \quad \frac{d^2(\ln \delta)}{d\lambda^2},$$

que se sustituyen dentro de las ecuaciones de evolución del crecimiento para calcular los residuos correspondientes. Estos residuos representan qué tanto se está violando la ecuación física en los puntos del dominio.

La función de pérdida fue definida como:

$$\mathcal{L} = \mathcal{L}_{\text{datos}} + \mathcal{L}_{\text{PDE}},$$

donde:

- $\mathcal{L}_{\text{datos}}$ mide el error entre la PINN y la solución simulada mediante integración numérica.
- $\mathcal{L}_{\text{PDE}}$ cuantifica el incumplimiento de las ecuaciones (4) y (5) en cada punto del dominio físico.

Este enfoque garantiza que la solución aprendida no solo se ajuste a los datos, sino que además respete la estructura matemática del crecimiento lineal en cosmología.

2.3.2 Esquema de entrenamiento

El entrenamiento se realizó mediante el optimizador Adam, actualizando los parámetros de la red en cada época para minimizar la función de pérdida total. A lo largo del entrenamiento, se monitorea el coeficiente de determinación R^2 tanto para el conjunto de entrenamiento como para el de validación, con el fin de evaluar el ajuste y detectar posibles problemas de sobreajuste o subajuste.

Cada escenario cosmológico (w, f_ν) se entrena de manera independiente, manteniendo fija la arquitectura de la red y los hiperparámetros, lo cual permite comparar el impacto de cada parámetro sobre la dinámica del crecimiento estructural. Los parámetros definidos fueron extraídos del artículo Kiakotou *et al.* [2007], además los escenarios (w, f_ν) evaluados están basados en los resultados presentados en ese artículo.

2.3.3 Evaluación del modelo

La evaluación del desempeño de la PINN se lleva a cabo en tres etapas:

1. **Validación de la arquitectura de la PINN:** Se genera una comparación visual y de evaluación mediante la métrica R^2 de la ecuación $y'' = 2y$ que se asemeja al comportamiento de la ecuación 4. Esto con el objetivo de garantizar que la arquitectura escogida es capaz de aproximar la solución de este tipo de ecuaciones de forma satisfactoria.
2. **Comparación gráfica:** Se contrasta visualmente la solución de referencia obtenida mediante integración numérica con la predicción de la PINN en términos de $\delta(z)$.
3. **Monitoreo de métricas:** Se registran y grafican las curvas de R^2 a lo largo de las épocas tanto para los datos de entrenamiento como de prueba para asegurarse que no haya un sobreajuste en la red.
4. **Evaluación cuantitativa:** Se calcula RMSE, MAE, MAPE y R^2 para cuantificar la precisión de la aproximación obtenida por la PINN.

Este procedimiento permite validar la coherencia física de los resultados, la precisión numérica del modelo y la robustez del método ante variaciones en los

parámetros cosmológicos. El código con todo el procedimiento llevado a cabo y los resultados se encuentra en Neutrinos y crecimiento cosmológico utilizando PINN's

3 Resultados

En esta sección se presentan los resultados obtenidos de la comparación del solver `odeint` comparado con la PINN generada.

Primero se presenta la gráfica de comparación para el funcionamiento de la PINN con una ecuación simple.




Figura 2. Gráfica comparativa de la solución de $y'' = 2y$ mediante la PINN y su solución exacta

Además de la figura 2, mediante la validación de la PINN se encontró que la aproximación tiene un $R^2 = 0.999884$.

Los siguientes resultados fueron obtenidos al entrenar la red propuesta durante 3000 épocas y comparando su resultado con el obtenido al resolver (4) usando `odeint` para los dos escenarios propuestos.




Figura 3. Aproximación de $\delta(z)$ mediante PINN's para $w = -1$ y $f_\nu = 0,04$

Métrica	Valor
R^2	0,948019
RMSE	$4,301590 \times 10^{-2}$
MAE	$3,449664 \times 10^{-2}$
MAPE	6,945 %

Tabela 1. Escenario 1 - Métricas $\delta(z)$

Métrica	Valor
R^2	0,913373
RMSE	$4,941380 \times 10^{-2}$
MAE	$3,911365 \times 10^{-2}$
MAPE	7,109 %

Tabela 2. Escenario 2 - Métricas $\delta(z)$




Figura 4. Aproximación de $\delta(z)$ mediante PINN's para $w = -0,08$ y $f_\nu = 0,04$

4 Discusión y Conclusiones

Se ha demostrado que el uso de una red neuronal informada por la física (PINN) para aproximar la solución de la ecuación diferencial que describe la evolución del crecimiento en presencia de neutrinos masivos produce predicciones satisfactorias tanto por métricas como por comparación gráfica. Este método mantiene la coherencia física del problema y sus curvas para $\delta(z)$ se asemejan a las curvas del artículo de Kiakotou *et al.* [2007], en comparación a las del solver que son más rígidas.

En primer lugar, el desempeño de la PINN mostró una dependencia significativa de la selección de puntos de entrenamiento, de su arquitectura y de la ponderación de los términos en la función de pérdida. Pequeñas variaciones en estos elementos alteran de manera apreciable la estabilidad del entrenamiento, lo que sugiere que el método, en su forma actual, carece de robustez intrínseca y requiere una calibración cuidadosa para evitar soluciones físicamente inestables.

Adicionalmente, el costo computacional asociado al entrenamiento supera al requerido por integradores numéricos estándar, incluso para la ecuación lineal considerada. Esto indica que, si bien las PINNs ofrecen ventajas conceptuales, como la obtención directa de soluciones suaves y diferenciables, su eficiencia práctica sigue siendo inferior cuando se trata de problemas bien caracterizados y con soluciones numéricas ya consolidadas.

La aplicación de PINN's en cosmología aún enfrenta desafíos metodológicos importantes. La extensión del enfoque a escenarios no lineales, sistemas acoplados o modelos dependientes de parámetros cosmológicos adicionales probablemente demandará técnicas más sofisticadas de entrenamiento y una mejor comprensión de cómo incorporar restricciones físicas de manera óptima dentro de la estructura de la red, además de una elección óptima de arquitectura y probablemente una cantidad cada vez mayor de épocas de entrenamiento.

En conclusión, aunque las PINN's constituyen una herramienta prometedora para la resolución de ecuaciones diferenciales en cosmología, su uso no está exento de limitaciones. El presente estudio evidencia tanto su potencial como sus desafíos, destacando la necesidad de investigaciones adicionales orientadas a mejorar la estabilidad, eficiencia y escalabilidad del método. Se propone para próximos estudios el uso de redes neuronales alternativas, como *Fourier Neural Networks* (FFN)

y comparar tanto calidad de las aproximaciones como costo computacional.

Referencias

- Ahmad, Q. R. *et al.* (2002). Direct evidence for neutrino flavor transformation from neutral-current interactions in the sudbury neutrino observatory. *Physical Review Letters*, 89(1):011301. DOI: 10.1103/PhysRevLett.89.011301.
- Brookfield, A. W., van de Bruck, C., Hall, L. M. H., and Mota, D. F. (2007). Cosmology with massive neutrinos coupled to dark energy. *Physical Review D*, 76:083515. DOI: 10.1103/PhysRevD.76.083515.
- Fukuda, Y. *et al.* (1998). Evidence for oscillation of atmospheric neutrinos. *Physical Review Letters*, 81:1562–1567. DOI: 10.1103/PhysRevLett.81.1562.
- Group, P. D. (2024). Review of particle physics. *Progress of Theoretical and Experimental Physics*, 2024(8):083C01.
- Kiakotou, A., Elgarøy, O., and Lahav, O. (2007). Neutrino mass, dark energy, and the linear growth factor. *arXiv preprint arXiv:0709.0253*.
- Lesgourgues, J. and Pastor, S. (2006). Massive neutrinos and cosmology. *Physics Reports*, 429(6):307–379. DOI: 10.1016/j.physrep.2006.04.001.
- Raissi, M., Perdikaris, P., and Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707.